Liquid d1における短文QAの画像入力と縮小の影響

Belebele英語・日本語サブセットによる探索的評価

技術報告・未査読｜2026年10月7日 実験実行・保存記録：Codex。結果整理・考察：ChatGPT。本文は保存結果の整理で、新しい推論は行っていない。

要旨

同一文脈をテキストまたは画像で与えた際の4択QA正答率、入力トークン、API応答時間、費用を比較した。第一段階の比較可能な各言語14問では、テキストA、画像B、上下分割Cがすべて正解したが、B/Cの入力量はAの英語2.59倍、日本語1.98倍だった。画像を縦横約40%へ縮小したD40の追試では、英語は14/14正解を維持して入力7.27%減、日本語は入力22.54%減と引き換えに11/14正解へ低下した。D40の応答時間中央値は旧Aより長かったが、別セッションのため速度差の因果比較はできない。正答率を優先する運用ではAを基本方式として維持し、英語D40はこの小集合で有望な候補にとどめる。

1. 背景と目的

DeepSeek-OCRの光学的な文脈圧縮に着想を得て、画像対応d1でも文脈の画像化が実用上の利益を生むかを確認した。DeepSeek-OCRの再現実験ではなく、OCRによる文字復元精度も測定していない。本稿の対象は選択肢の確率を返すd1の4択QA正答率である。モデル固有の視覚表現と、API課金上の入力トークンも同一視しない。[E1] [E3]

2. 方法

2.1 データ・入力

Belebeleの英語 eng_Latn と日本語 jpn_Jpan を用いた。短い本文・質問・4選択肢・唯一の正解を備える対訳データであり、独自の誤答選択肢を生成する工程を避けた。16の異なる本文・質問を英日で対応させ、各言語の正解位置A/B/C/Dが4件ずつになるよう事前選定した。描画適格性・内容監査を伴い、全データの無作為標本ではない。調整用の自作予備4問と本評価を分離した。原本文・質問・正解を保持し、API候補の両端空白だけを既存実装に従って除いた。[E2]

条件	本文の表現	位置づけ
A	原本文のテキスト	基準
B	本文全文のPNG 1枚	通常サイズの画像入力
C	Bを行間で上下2枚へ切り、順番に同時送信	分割の効果。縮小ではない
N	本文なし。質問・選択肢のみ	文脈なし正解の診断
D50	B全体を縦横約50%へ縮小	費用推計のみ。推論未実施
D40	B全体を縦横約40%へ縮小	第二段階で実測

Bは幅768px、文字24px、行高32px、上下左右余白32px、横書き1段、白背景・黒字。フォントは英語Noto Sans、日本語Noto Sans JP。本文がL行なら高さは(L+2)×32px。Cは再描画せず切り出し、再結合とBの全画素一致を検証した。D40は作成済みBをLANCZOSで全体縮小し、幅308px、高さceil(2H/5)とした。24px文字は名目約9.6px相当になる。再組版・本文省略・部分切り取りはしないが、縮小は不可逆で、文字情報の完全保持を保証しない。

質問・選択肢・候補順序・共通英語指示はテキストのまま固定し、画像に原本文のテキストや正解を添えなかった。D40はBの画像だけを差し替えた。D50は英語でA比9.6%増、日本語で11.3%減の入力見込みだったため、両言語で節約が見込める単一候補としてD40を選んだ。D50のNO_GOは日本語単独での可能性を否定する結果ではない。

2.2 実行・採点・計測

第一段階は2026年10月7日07:20～07:22（日本時間）に実行した。予備16回答、本評価113回答を取得し、本評価114回目のAで通信失敗。未送信14回を残して停止した。各条件16問の事前主指標は未完了のnullを維持し、本稿はA/B/Cがそろう各言語14問を補助比較する。第二段階は同日13:57～13:58、同じ14問×英日と予備2回の計30回を実行した。追試の主分母は事前に各言語14と固定し、予備は含めない。英日共通の本文・質問は12件であり、28独立題とは扱わない。

採点は丸め前の4確率のargmaxと公式正解の一致。同率はA→B→C→D順。正解候補の確率そのものを点数にしない。期待したd1の有効回答、使用量・費用の確認状態、未試行を区別した。各段階は並列1・自動再試行0、接続10秒／読み取り60秒、段階内は同一HTTPセッション。第一段階は条件順を均衡化し、第二段階は固定順で英日を交互に送信した。予備の正答率ではなく、形式・usage・費用の技術条件を続行判定に用いた。

速度はHTTP送信から応答本文受領までの時間で、ネットワーク・アップロードを含む。サーバー内部の推論時間ではない。画像生成・送信準備・API時間を分離した。費用は全入力usage×0.04 USD／100万tokensで計算し、API報告額と照合した。 [E3]

3. 結果

3.1 正答率・入力・費用

A/B/Cは第一段階の共通14問に限る補助集計、D40は第二段階の固定14問の結果。言語内では同じ問題を比較する。全入力は本文以外の質問・候補等も含む。費用は同じ14問の単価計算額であり、実請求額ではない。

言語	条件	正解／14	入力tokens	旧A比	費用（USD／14問）
英語	A	14/14	2,669	基準	0.00010676
英語	B	14/14	6,921	+159.31%	0.00027684
英語	C	14/14	6,921	+159.31%	0.00027684
英語	D40	14/14	2,475	-7.27%	0.00009900
日本語	A	14/14	3,407	基準	0.00013628
日本語	B	14/14	6,749	+98.09%	0.00026996
日本語	C	14/14	6,749	+98.09%	0.00026996
日本語	D40	11/14	2,639	-22.54%	0.00010556

日本語D40は正答率100%→78.57%、21.43ポイント低下。英語の削減量は194tokens／0.00000776 USD、日本語は768tokens／0.00003072 USD（いずれも14問分）。D40の事前推計と実測全入力は本評価28件で項目ごとに一致した。ただし合計の削減であり、全問が安くなったわけではない。例えば英語の2c04e1baf853dcf2はA150→D40160tokensと増えている。

3.2 速度

条件	英語 API中央値［IQR］ms	日本語 API中央値［IQR］ms
A	296.20［40.72］	308.66［38.10］
B	436.35［105.41］	528.65［125.64］
C	461.87［80.21］	578.65［136.77］
D40	481.45［107.91］	402.23［245.73］

各セル14有効回答。IQRは第3四分位数と第1四分位数の差。D40/旧Aの中央値比は英語約1.63、日本語約1.30で、観測上はどちらも旧Aより遅い。ただし別セッションで内部モデル版も固定できておらず、縮小が遅さの原因だとは断定できない。少なくとも高速化を裏付ける結果は得られていない。

第一段階130試行のAPI待ち時間合計は74.091秒で、通信失敗1件の19.186秒を含む。この失敗は上表の中央値に入らない。D40の30試行では失敗待ち0、API待ち時間合計約15.937秒、段階全体の経過時間約18.511秒だった。第一段階36本文分の描画1.580秒・分割1.128秒は以前の別計測で、D40時間へ機械的に加算しない。D40画像は事前生成済みであり、画像生成込みの速度優位は評価していない。

3.3 本文なし条件とJev参考値

比較対象	英語	日本語
N：同じ14問の本文なし	10/14	11/14
A/B/C	各14/14	各14/14
D40	14/14	11/14
過去Jev：同じ14問	14/14	14/14
N誤答項目に限ったD40（事後診断）	4/4	1/3

本文なしでも多くに正解するため、満点だけで画像の全文を正確に読んだとは言えない。日本語のD40とNは同じ11/14でも誤答集合は異なる。N誤答3件中1件はD40で正解し、N正解だった別の1件はD40で誤答した。Nの結果から暗記・データ汚染を断定せず、主集合も選び直さない。

Jevは過去の公開jev-1.13.0応答の同一項目再採点で、新規推論なし。d1との同時測定ではなく、満点の小集合から一般的な同等性は導けない。文献の全122言語Belebele成績86.7%も今回とは分母が異なり直接比較しない。 [E4]

4. 日本語の誤答

項目ID末尾／内容	正解	D40	正解候補の確率	本文なしN
2c04e1baf853dcf2／本文中の承認対象	D：新しい共和国	A：地域名	37.27%	誤答
9adaf5d3889f99f4／インターネット通話	A：インターネット経由	B：グローバル番号	35.92%	誤答
7b74b887ed8f5cd1／選手の経歴	A：1945年にデビュー	B：別クラブで活躍	6.12%	正解

項目名はデータの内容要約で、現実世界の現在の事実認定ではない。B/Cでは3件とも正解だった。細部の識別低下や本文と候補の関係づけの失敗は原因候補だが、OCR出力を取得していないため、どの文字を読み違えたかは確認できない。別セッション・内部版未固定の交絡も残る。

5. 実験全体の費用

区分	回答取得数	入力tokens	単価計算額＝API報告額（USD）
第一段階・予備込み	129	40,607	0.00162428
D40・予備込み	30	5,466	0.00021864
既知分の合計	159	46,073	0.00184292

送信開始は160回で、1回は旧通信失敗のため応答・費用不明。見積もり予約0.01 USDを保持し、実際に使った金額とはしない。既知額＋予約0.01184292 USDも、提供元保証の最大請求額ではない。全実験の確定総額・実請求額は未確認である。

6. 考察・限界・結論

画像を読めること、入力が減ること、正答を維持できること、速くなることは別の評価軸だった。Bは正答を維持しても入力が増え、D40は入力を減らしても日本語の正答を失った。画像の計数はceil(1.5 × ceil(W/32) × ceil(H/32))で、質問等の非画像分は残る。付録例のBは768×256pxで288画像tokens、D40は308×103pxで60画像tokens。画像部分の約79%削減を、テキストAに対する全入力の約79%削減とは解釈できない。 [E3]

一般化を制限するのは、各言語14問・単回、短文・4択・限定フォント、事前選定と欠測、本文なし正解の多い公開データ、第一段階の満点を知った後に同じ集合で行った探索的追試、D40とAの別セッション・内部版／キャッシュ不明である。1問は7.14ポイントに相当する。言語間の能力差、長文での最適条件、OCR復元精度、統計的同等性は主張しない。

標準運用はテキストAを維持する。英語D40はこの14問で有望、日本語D40は不採用。 英語の節約額は小さく、画像生成・管理の手間と未確定の速度差を考えると直ちに標準方式を置き換える根拠には乏しい。日本語では22.54%入力削減より3/14件の正答喪失を重く見る。画像入力一般の否定ではなく、本条件に対する精度優先の判断である。

付録A. 実際に送信した画像を開く

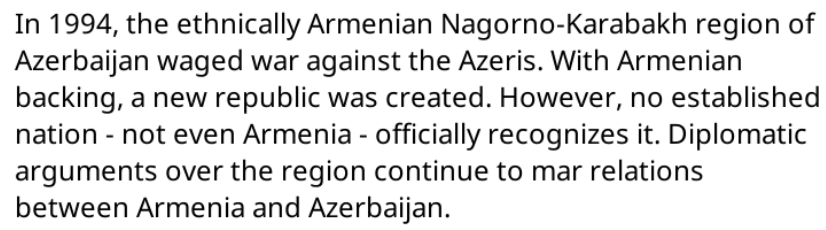
以下の10点は実際にモデルへ送信したPNGそのもので、説明用に再生成した画像ではない。本文だけを画像とし、質問と選択肢はテキストで別送した。リンクは本公開資料内の画像を参照する。画面やPDFでは表示サイズが変わるため、元の画素数と区別する。

実入力例	B：通常画像	C：上下2枚	D40：縮小画像
英語・承認対象の設問	Bを開く	上／下	D40を開く：正解
日本語・同じ設問	Bを開く	上／下	D40を開く：誤答

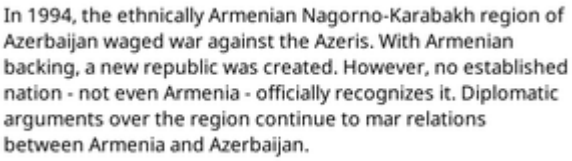
ほかの日本語誤答画像：インターネット通話／選手の経歴。

英語：BとD40

B（正解、768×256px）：

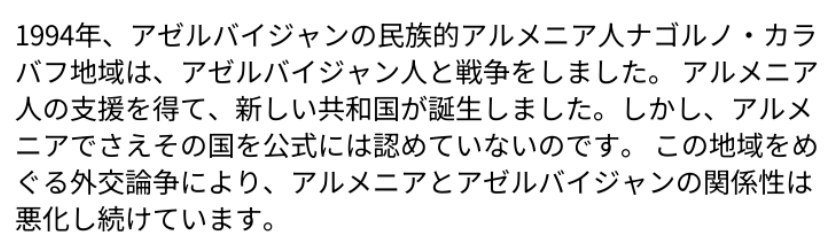

In 1994, the ethnically Armenian Nagorno-Karabakh region of Azerbaijan waged war against the Azeris. With Armenian backing, a new republic was created. However, no established nation - not even Armenia - officially recognizes it. Diplomatic arguments over the region continue to mar relations between Armenia and Azerbaijan.

D40（正解、308×103px）：

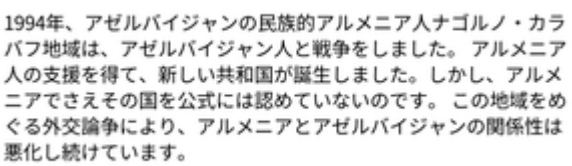

In 1994, the ethnically Armenian Nagorno-Karabakh region of Azerbaijan waged war against the Azeris. With Armenian backing, a new republic was created. However, no established nation - not even Armenia - officially recognizes it. Diplomatic arguments over the region continue to mar relations between Armenia and Azerbaijan.

日本語：BとD40

B（正解、768×256px）：


1994年、アゼルバイジャンの民族的アルメニア人ナゴルノ・カラバフ地域は、アゼルバイジャン人と戦争をしました。 アルメニア人の支援を得て、新しい共和国が誕生しました。しかし、アルメニアでさえその国を公式には認めていないのです。 この地域をめぐる外交論争により、アルメニアとアゼルバイジャンの関係性は悪化し続けています。

D40（誤答、308×103px）：


1994年、アゼルバイジャンの民族的アルメニア人ナゴルノ・カラバフ地域は、アゼルバイジャン人と戦争をしました。 アルメニア人の支援を得て、新しい共和国が誕生しました。しかし、アルメニアでさえその国を公式には認めていないのです。 この地域をめぐる外交論争により、アルメニアとアゼルバイジャンの関係性は悪化し続けています。

付録B. 出典・検証範囲・ライセンス

• [E1] Wei, Sun, Li. DeepSeek-OCR: Contexts Optical Compression. arXiv:2510.18234, 2025.

• [E2] Bandarkar et al. The Belebele Benchmark: a Parallel Reading Comprehension Dataset in 122 Language Variants. ACL 2024. Facebook Research公式リポジトリ。評価データCC BY-SA 4.0。

• [E3] Liquid AI. Introducing d1: The most capable decision model, now with vision. 2026-10-05.

• [E4] Deußer, Sparrenberg, Sifa. Evaluating and Benchmarking the System One Model Jev. arXiv:2609.37647, 2026.

本稿作成時に159原応答をすべて独立に再採点したものではない。主要確定報告、個別結果の該当行、送信メタデータ、プロトコルを読み、掲載集計値の算術を再確認した。全原応答との一致は保存されたCodexの照合記録に依拠する。実画像の目視監査記録もCodexによるもので、独立した人の監査とはしない。文献は背景・API説明、本実験の性能値は保存実測を出典とする。本公開資料は報告と掲載画像に限定され、原応答の独立再検証に必要な資料一式は含まない。

Belebele由来の本文・引用および派生PNG（本稿中の掲載図を含む）は、Facebook ResearchのBelebele評価データに由来し、CC BY-SA 4.0で提供する。画像化は本実験による変更で、Bは本文の描画、Cは上下分割、D40は全体縮小を施した。公開するPNGは実送信後に加工していない。元の文章内容と誤記は修正していない。

Belebeleの本文はFLORESに由来する。掲載例に記録された元記事とその寄稿者への帰属は次のとおり（記事の現在の記述との同一性は主張しない）。

• 承認対象の英日例：Wikivoyage, Caucasus の寄稿者。

• インターネット通話例：Wikivoyage, Internet telephony の寄稿者。

• 選手の経歴例：Wikinews, Former Yugoslavian footballer Stjepan Bobek dies aged 86 の寄稿者。

その他の論文本文：Research report © repository owner。研究・評価の技術報告であり、モデル再学習を目的としない。